



**Vilniaus
universitetas**

Klasterizavimo algoritmų analizė

Darbo tikslas

Šio darbo tikslas – pritaikyti ir išnagrinėti DBSCAN klasterizavimo algoritmą skirtingiems EKG duomenų rinkiniams, išskirti klasterius ir apibrėžti jų specifiką.

Tiriami duomenų rinkiniai

Duomenų aibė yra sudaryta iš EKG signalų pūpsnių.


Tiriami 3 duomenų rinkiniai:

- Pilnas požymių rinkinys (31 kiekybinis požymis)
- 7 atrinktų požymių rinkinys
- Geriausia UMAP 2D projekcija (kaimynų skaičius: 200, mažiausias atstumas: 0,5)

Klasterių kokybės vertinimo rodikliai

- Vid. silueto įvertis – parodo, kaip gerai taškai priskirti savo klasteriams intervale $[-1, 1]$.
- ARI (Adjusted Rand Index) – įvertina, kiek gauti klasteriai sutampa su tikrosiomis duomenų klasėmis intervale $[-1, 1]$.
- NMI (Normalized Mutual Information) – matuoja informacijos kiekį, kurį klasterių struktūra dalijasi su tikrosiomis klasėmis intervale $[0, 1]$.
- Bendras kokybės indeksas – vid. silueto, ARI, NMI vidurkis.

DBSCAN




Optimalaus eps parametro nustatymas naudojant knee metodą

- Naudojama kNN distancijų kreivė.
- Knee taškas – vieta, kur kreivė staiga pradeda staigiai augti, tai žymi ribą tarp tankaus regiono ir triukšmo.
- Automatinis knee taško nustatymas naudojamas pradiniam klasterizavimui.
- Parametrų keitimo analizei naudoti vizualiai aptikti eps kreivėje.

DBSCAN - Pilnas požymių rinkinys

Vilniaus
universitetas

kNN distancijų kreivė - Pilnas rinkinys (31 požymis) $\text{eps}=1,227$



Rikiuoti taškai

Atlikti bandymai:


$\text{eps}=0,8$ $\text{MinPts}=32$

$\text{eps}=0,9$ $\text{MinPts}=45$



$\text{eps}=1$ $\text{MinPts}=70$

$\text{eps}=1,1$ $\text{MinPts}=80$

DBSCAN klasterizavimas – visi požymiai ($\text{eps}=1.277$, $\text{MinPts}=62$)




DBSCAN – 7 požymių rinkinys




DBSCAN – 7 požymių rinkinys

Vilniaus
universitetas

DBSCAN klasterizavimas – 7 požymiai (eps=0.25, MinPts=14)





Triukšmą daugiausia sudarė 1 ir 2 klasės išskirtys. Pirmą klasterį sudarė beveik vienodas kiekis įrašų iš kiekvienos klasės, kur dominavo normalios reikšmės, mažesnę dalį sudarė išskirtys, iš jų mažiausiai – sąlyginės išskirtys. Antrą klasterį sudarė tik antros klasės išskirtys.



Eksperimentai su parametrais eps=0,3, eps=0,4 ir eps=0,65 formavo tik vieną klasterį, bet skirtingą triukšmo taškų skaičių

Silueto įvertis	0,2978
ARI	0,0092
NMI	0,0478
Bendras kokybės indeksas	0,1183

DBSCAN - Geriausia UMAP 2D projekcija




Silueto įvertis	0,5727
ARI	0,3559
NMI	0,3242
Bendras kokybės indeksas	0,4176

3 klasterį sudarė tik 2 klasės išskirtys

DBSCAN - Geriausia UMAP 2D projekcija

Vilniaus universitetas

DBSCAN klasterizavimas – geriausia UMAP projekcija (eps=0.5, MinPts=4)




Klasteris	Iš viso įrašų	0 klasės įrašų	1 klasės įrašų	2 klasės įrašų	Įrašų be išskirčių	Mild išskirčių	Extreme išskirčių
Triukšmas	18	3	11	4	5	3	10
1	707	411	41	255	443	105	159
2	104	86	18	0	95	9	0
3	302	0	273	29	281	17	4
4	78	0	75	3	0	1	77
5	86	0	82	4	0	0	86
6	57	0	0	57	0	0	57
7	148	0	0	148	10	56	82

Silueto įvertis	0,4881
ARI	0,2945
NMI	0,3597
Bendras kokybės indeksas	0,3808

DBSCAN - Geriausia UMAP 2D projekcija

Vilniaus universitetas



Klasteris	Iš viso įrašų	0 klasės įrašų	1 klasės įrašų	2 klasės įrašų	Įrašų be išskirčių	Mild išskirčių	Extreme išskirčių
Triukšmas	7	2	3	2	1	3	3
1	709	412	41	256	444	105	160
2	500	86	380	34	379	26	95
3	79	0	76	3	0	1	78
4	57	0	0	57	0	0	57
5	148	0	0	148	10	56	82


40

Silueto įvertis	0,447
ARI	0,2955
NMI	0,3614
Bendras kokybės indeksas	0,3680

Trys buvę klasteriai su eps=0,5 susijungė į vieną didesnę

DBSCAN - Geriausia UMAP 2D projekcija

Vilniaus universitetas



Sumažėjo tik triukšmo
taškų skaičius, buvę
taškai pasiskirstė į 1, 2 ir
3 klasterį.

Klasteris	Iš viso įrašų	0 klasės įrašų	1 klasės įrašų	2 klasės įrašų	Įrašų be išskirčių	Mild išskirčių	Extreme išskirčių
Triukšmas	2	0	1	1	0	1	1
1	710	413	41	256	445	105	160
2	503	87	381	35	379	27	97
3	80	0	77	3	0	2	78
4	57	0	0	57	0	0	57
5	148	0	0	148	10	56	82


41

Silueto įvertis	0,4462
ARI	0,3508
NMI	0,4023
Bendras kokybės indeksas	0,3998


DBSCAN - Geriausia UMAP 2D projekcija

Vilniaus universitetas

DBSCAN klasterizavimas – geriausia UMAP projekcija (eps=0.75, MinPts=4)



DBSCAN klasterizavimas – geriausia UMAP projekcija (eps=0.8, MinPts=4)



Silueto įvertis	0,445
ARI	0,3157
NMI	0,3679
Bendras kokybės indeksas	0,3762


42

Silueto įvertis	0,5727
ARI	0,3054
NMI	0,3334
Bendras kokybės indeksas	0,4038

7 požymių aibės geriausia projekcija

Vilniaus
universitetas

DBSCAN klasterizavimas – 7 požymiai (eps=0.25, MinPts=14)




Silhouette	ARI	NMI	Bendras kokybės indeksas
0,298	0,009	0,048	0,118

Klasteris	Iš viso įrašų	0 klasės įrašų	1 klasės įrašų	2 klasės įrašų	Įrašų be išskirčių	Mild išskirčių	Extreme išskirčių
Triukšmas	50	3	14	33	0	2	48
1	1396	497	486	413	834	189	373
2	54	0	0	54	0	0	54

Geriausia UMAP 2D projekcija

DBSCAN klasterizavimas – geriausia UMAP projekcija (eps=0.885, MinPts=4)




Silhouette	ARI	NMI	Bendras kokybės indeksas
0,5727	0,3559	0,3242	0,4176

Klasteris	Iš viso įrašų	0 klasės įrašų	1 klasės įrašų	2 klasės įrašų	Įrašų be išskirčių	Mild išskirčių	Extreme išskirčių
1	858	413	41	404	455	161	242
2	585	87	459	39	379	30	176
3	57	0	0	57	0	0	57

Geriausios UMAP 2D projekcijos aprašomoji statistika

Vilniaus
universitetas

7 Požymių reikšmės pagal UMAP klasterius (Normalizuota skalė [0, 1])



DBSCAN algoritmas

Geriausių UMAP 2D projekcijų aprašomoji statistika

DBSCAN algoritmo aprašomoji statistika skiriasi RR_I_0 ir RR_I_0/RR_I_1 požymiuose.

Požymis	RR_I_0			RR_I_0/RR_I_1			P_val			Q_val			R_val			S_val			signal_std		
Klasteris	1	2	3	1	2	3	1	2	3	1	2	3	1	2	3	1	2	3	1	2	3
Vidurkis	0,14	0,185	0,141	0,327	0,332	0,395	0,437	0,317	0,53	0,493	0,481	0,102	0,53	0,228	0,293	0,395	0,405	0,528	0,364	0,084	0,477
Min	0	0	0,028	0,021	0	0,128	0	0,191	0,457	0,252	0,306	0	0,059	0	0,195	0	0,316	0,414	0,133	0	0,338
Max	0,443	1	0,228	0,787	1	0,657	1	0,473	0,713	1	0,651	0,176	1	0,482	0,61	1	0,586	0,764	1	0,366	0,692

Išvados

Dimensijos mažinimas labai pagerino klasterizavimo rezultatus su visais klasterizavimo metodais.

Su DBSCAN algoritmu geriausia projekcija buvo pasiekta, kai $k = 5$ ir $\text{silhouette} = 0,4462$, $\text{ARI} = 0,351$, $\text{NMI} = 0,402$ ir bendras rodiklių indeksas $= 0,399$.