



**Vilniaus
universitetas**



Daugiamatčių duomenų dimensijos mažinimas

Darbo tikslas

Šiame darbe siekiama išnagrinėti dimensijos mažinimo metodų PCA, UMAP taikymo galimybes daugiamatčių duomenų vizualizavimui.

Tiriamos duomenų aibės aprašymas

Duomenų aibė yra sudaryta iš EKG signalų pūpsnių.

Požymis	Kintamojo reikšmė, tipas
RR_I_0	Skaitinis, kiekybinis
RR_I_0/RR_I_1	Skaitinis, kiekybinis
P_val	Skaitinis, kiekybinis
Q_val	Skaitinis, kiekybinis
R_val	Skaitinis, kiekybinis
S_val	Skaitinis, kiekybinis
signal_std	Skaitinis, kiekybinis
label	Nominalusis, kokybinis

Pilnos duomenų aibės specifika

Pilną duomenų aibę sudaro 31 kiekybinis požymis ir 1 kokybinis.

- Duomenų aibės tipas: lentelė.
- Duomenų aibės dydis: $m = 11940$, didelė.
- Duomenų dimensija: $n = 31$, maža.
- Vidinės dimensijos santykinis matas: $\rho_n = 0,548$, didelis.
- Retumo santykio matas: $\gamma_n = 0,0003$, tankus.

Tiriamos duomenų aibės specifika

Tiriamą duomenų aibę sudaro 7 atrinkti kiekybiniai požymiai.

- Duomenų aibės tipas: lentelė.
- Duomenų aibės dydis: $m = 1500$, vidutinė.
- Duomenų dimensija: $n = 7$, maža.
- Vidinės dimensijos santykinis matas: $\rho_n = 0,857$, didelis.
- Retumo santykio matas: $\gamma_n = 0,00019$, tankus.

Pilnos duomenų aibės praleistų reikšmių tvarkymas

- Praleistos reikšmės rastos stulpeliuose, RR_l_3, RR_r_0, RR_r_3, signal_std, S_pos, po vieną kiekvienne (0,07%) bei dvi stulpelyje RR_l_2/RR_l_3 (0,13%).
- Praleistos reikšmės užpildytos medianomis.
- Likę požymiai be praleistų reikšmių.

Atrinktų požymių aprašomoji statistika

	Vidurkis		Sklaida	
	Didžiausias	Mažiausias	Didžiausia	Mažiausia
RR_I_0	174,78 (1 kl.)	145,93 (2 kl.)	85,32 (1 kl.)	26,41 (0 kl.)
RR_I_0/RR_I_1	1,17 (2 kl.)	1,01 (0 kl.)	0,59 (1 kl.)	0,18 (0 kl.)
P_val	0,61 (2 kl.)	-0,14 (1 kl.)	0,49 (2 kl.)	0,15 (1 kl.)
Q_val	-0,21 (1 kl.)	-0,43 (0 kl.)	0,81 (2 kl.)	0,14 (1 kl.)
R_val	1,56 (0 kl.)	0,65 (1 kl.)	0,67 (2 kl.)	0,34 (1 kl.)
S_val	-0,33 (2 kl.)	-0,54 (0 kl.)	0,79 (2 kl.)	0,21 (1 kl.)
signal_std	0,52 (2 kl.)	0,16 (1 kl.)	0,18 (2 kl.)	0,08 (1 kl.)

Dimensijos mažinimo metodai

Taikant dimensijos mažinimo metodus atlikta:

- Vizualizacija pilnai duomenų aibei su nenormuotais duomenimis.
- Vizualizacija pilnai duomenų aibei su min-max normuotais duomenimis.
- Vizualizacija tiriamai duomenų aibei su nenormuotais duomenimis.
- Vizualizacija tiriamai duomenų aibei su min-max normuotais duomenimis.

PCA metodas

PCA (Principal Component Analysis) tai tiesinis metodas, kuris ieško naujų ašių, apibūdinančių didžiausią duomenų variaciją.


1. Pirmiausia apskaičiuojama duomenų dispersija, t. y. kaip stipriai kinta kiekvienas požymis.
2. Tuomet atliekamas ašių pasukimas – algoritmas randa naujas kryptis, kurios geriausiai paaiškina duomenų skirtumus.
3. Kiekviena nauja kryptis (pagrindinė komponentė) tiesiškai nekoreliuoja su kitomis, todėl informacija jose nesidubliuoja.
4. Po šios transformacijos galima naudoti tik pirmas kelias komponentes, jos paprastai išlaiko daugiausiai pradinės informacijos.

PCA geriausios vizualizacijos

Vilniaus
universitetas

PCA - Pilna požymių aibė (normuoti)

Dimensijos sumažintos iki dim=2



Klasė


- 0
- 1
- 2

Išskirtys

- Normal
- Mild
- Extreme

Normuoti duomenys (min-max) su visomis išskirtimis (PCA)

Dimensijos sumažintos iki dim=2



UMAP metodas

UMAP (Uniform Manifold Approximation and Projection) – netiesinis metodas, kuris išlaiko tiek vietinius, tiek bendrus ryšius tarp taškų.


1. Algoritmas suranda kiekvieno duomenų taško artimiausius kaimynus ir įvertina, kurie taškai yra labiausiai panašūs vienas į kitą.
2. Remdamasis šiais panašumais, UMAP sukuria grafą, kuris aprašo duomenų struktūrą aukštesnėje dimensijoje.
3. Vėliau algoritmas projektuoja duomenis į mažesnę erdvę ($\text{dim}=2$), stengdamasis išlaikyti tą patį panašumų išsidėstymą kaip ir pradinėje erdvėje.
4. Procesas optimizuojamas naudojant gradientinio nusileidimo principą, kad gautas mažesnės dimensijos atvaizdas kuo tiksliau atspindėtų duomenų santykius.

UMAP geriausios vizualizacijos

Vilniaus
universitetas


UMAP - Pilna požymių aibė (normuoti)

Dimensijos sumažintos iki dim=2



Normuoti duomenys (min-max) su visomis išskirtimis (UMAP)


Dimensijos sumažintos iki dim=2




Algoritmo parametrų keitimo analizė

Vilniaus
universitetas

Lokalių struktūrų pabrėžimo eksperimentas
Kaimynų skaičius 5



Globalios struktūros pabrėžimo eksperimentas
Kaimynų skaičius 50



Klasė

- 0
- 1
- 2

Išskirtys


- Normal
- Mild
- Extreme

Metodų privalumai bei trūkumai

Metodas	Privalumai	Trūkumai
PCA	Išlaiko svarbiausią informaciją, pašalina koreliacijas tarp požymių	Veikia tik su tiesiniais ryšiais, prarandama dalis informacijos
UMAP	Išlaiko lokalius ir globalius ryšius, tinka didesnių duomenų vizualizacijai	Rezultatai priklauso nuo parametrų, ne visada išlaiko tikslius atstumus

Metodų palyginimas

Vilniaus
universitetas



Išvados

Visi metodai parodė panašias bendras duomenų tendencijas – be normavimo klasės stipriai persidengia, o po normavimo tampa aiškiau atskirtos.

Ryškiausiai išsiskiria 2 klasė (ventrikulinis virpėjimas), o 0 ir 1 klasės lieka arčiau viena kitos.

UMAP labiau pabrėžė lokalius ryšius ir klasių grupavimą, tuo tarpu PCA geriau atspindėjo bendrą duomenų struktūrą.

Tai rodo, kad duomenų mastelio suvienodinimas yra būtinas, norint teisingai atvaizduoti jų vidinius ryšius ir išvengti klaidinančio persidegimo.