



**Vilniaus
universitetas**



Klasifikavimo metodų analizė

Darbo tikslas

Šio darbo tikslas – įvertinti kNN, Random Forest ir Decision Tree klasifikavimo modelius, leidžiančius prognozuoti klases remiantis turimais duomenimis. Tam siekiama išanalizuoti ir atrinkti informatyviausius požymius, pritaikyti kelis skirtingus algoritmus bei parinkti jiems tinkamiausius parametrus. Darbe taip pat numatyta įvertinti modelių tikslumą, stabilumą ir bendrą prognozavimo kokybę, kad būtų galima nustatyti, kuris algoritmas yra efektyviausias šiam duomenų rinkiniui.

Tiriamas duomenų rinkinys

Duomenų aibė yra sudaryta iš EKG signalų pūpsnių, kur buvo 0 ir 2 klasės įrašai:

- Duomenų aibės tipas: lentelė.
- Duomenų aibės dydis: $m = 2000$, vidutinė.
- Duomenų dimensija: $n = 31$, maža.
- Vidinės dimensijos santykinis matas: $\rho_n = 0,516$, didelis.
- Retumo santykio matas: $\gamma_n = 0,00013$, tankus.

Duomenų aibės padalinimas

Duomenų aibė buvo padalinta į tris aibes, kur 80 % buvo naudojami modelio mokymui, o likę 20 % modelio tikslumo patikrinimui:

- 64 % duomenų (1280 įrašų) – mokymo aibė;
- 16 % duomenų (320 įrašų) – validavimo aibė;
- 20 % duomenų (400 įrašų) – testavimo aibė.

Duomenys buvo subalansuoti – kiekvienoje klasėje buvo vienodas įrašų kiekis.

Modelių kokybės vertinimo matai

- **Accuracy** – kiek modelio prognozių iš viso buvo teisingos – tiek teigiamų, tiek neigiamų;
- **Precision** – nusako, kiek iš modelio pažymėtų teigiamų atvejų iš tiesų yra teigiami;
- **Recall** – nusako, kiek iš visų tikrųjų teigiamų atvejų modelis sugeba teisingai identifikuoti;
- **F1** – įvertina klasifikatoriaus bendrą gebėjimą teisingai atpažinti teigiamus atvejus.

Požymių rinkinio atrinkimas

Pagal požymių accuracy kNN modeliui, MeanDecreaseAccuracy ir MeanDecreaseGini metrikas Random Forest modeliui ir požymių svarbą pagal Gini impurity Decision Tree modeliui buvo nustatyti 3 informatyviausi požymiai: RR_r_0/RR_r_1, wl_side ir P_val.

Klasifikavimo algortimas	Informatyviausi požymiai					
kNN	RR_r_0/RR_r_1	wl_side	P_val	Q_pos	R_pos	S_pos
Random Forest	RR_r_0/RR_r_1	wl_side	P_val	Q_pos	R_pos	R_val
Decision Tree	RR_r_0/RR_r_1	wl_side	P_val	signal_std	seq_size	RR_r_1

kNN klasifikavimo algoritmas

- Paprastas ir intuityvus mašininio mokymosi algoritmas.
- Nustato naujo taško klasę pagal K artimiausių mokymo duomenų taškų daugumos klasę.
- Remiasi prielaida: panašūs duomenų taškai yra arti vienas kito.
- Priklauso tingiųjų (angl. *lazy*) algoritmų grupei – neturi mokymo fazės, visi skaičiavimai atliekami klasifikavimo metu.

Veikimo principas:

1. Apskaičiuojamas atstumas tarp naujo taško ir visų mokymo taškų.
2. Parenkami K artimiausių kaimynų.
3. Atliekamas daugumos balsavimas.
4. Naujam objektui priskiriama dominuojanti klasė.

kNN optimalių parametų nustatymas

Vilniaus
universitetas

Numatytieji parametrai

Parametrai	Accuracy	Precision	Recall	F1	Sumaišymo matrica									
k=5	0.981250	0.9813252	0.981250	0.9812493	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>158</td><td>2</td></tr><tr><td>2</td><td>4</td><td>156</td></tr></table>		0	2	0	158	2	2	4	156
	0	2												
0	158	2												
2	4	156												

Geriausi parametrai nustatyti eksperimentuojant su nelyginėmis k reikšmėmis nuo 1 iki 51

Parametrai	Accuracy	Precision	Recall	F1	Sumaišymo matrica									
k=3	0.981250	0.9813252	0.981250	0.9812493	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>158</td><td>2</td></tr><tr><td>2</td><td>4</td><td>156</td></tr></table>		0	2	0	158	2	2	4	156
	0	2												
0	158	2												
2	4	156												
k=5	0.981250	0.9813252	0.981250	0.9812493	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>158</td><td>2</td></tr><tr><td>2</td><td>4</td><td>156</td></tr></table>		0	2	0	158	2	2	4	156
	0	2												
0	158	2												
2	4	156												

Požymių eiliškumo tyrimas (kNN)

Požymių eilės tvarka neturi jokios įtakos kNN klasifikatoriaus veikimui.


Accuracy	Precision	Recall	F1	Sumaišymo matrica									
0.978125	0.978293	0.978125	0.978123	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>158</td><td>2</td></tr><tr><td>2</td><td>4</td><td>156</td></tr></table>		0	2	0	158	2	2	4	156
	0	2											
0	158	2											
2	4	156											

Toliau tęsime su pradine požymių eilės tvarka: RR_r_0/RR_r_1, wl_side, P_val bei k=5.

Rinkinio sumažinimas iki dvimatės dimensijos (kNN)

Atlikus dimensijos mažinimą, modelis iš naujo apmokomas jau su dviejų dimensijų požymių rinkiniu ir pakartotinai atliekamas klasifikavimas.

Po dimensijos mažinimo iki dviejų požymių klasifikavimo rezultatai suprastėjo, lyginant su pradiniu trijų požymių rinkiniu.







UMAP parametrai	kNN parametrai	Accuracy	Precision	Recall	F1	Sumaišymo matrica									
n_neighbors = 200, min_dist = 0.5	k = 5, RR_r_0/RR_r_1, wl_side, P_val	0.971875	0.9723363	0.971875	0.9718681	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>158</td><td>2</td></tr><tr><td>2</td><td>7</td><td>153</td></tr></table>		0	2	0	158	2	2	7	153
	0	2													
0	158	2													
2	7	153													

10 Hold-out eksperimentų (kNN)





Hold-out 10 iteracijų
rezultatai su 3 požymių
rinkiniu

	Accuracy	Precision	Recall	F1
Vidurkis	0.9834375	0.9834922	0.9834375	0.9834370
Dispersija	0.0000696	0.0000694	0.0000696	0.0000696
Vidutinė klasifikavimo klaida	0.016562			
Klaidos standartinis nuokrypis	0.00834			



Hold-out iteracijų
rezultatai su sumažintu
iki UMAP 2D rinkiniu

	Accuracy	Precision	Recall	F1
Vidurkis	0.9703125	0.9704863	0.9703125	0.9703095
Dispersija	0.0001004	0.0000996	0.0001004	0.0001004
Vidutinė klasifikavimo klaida	0.029687			
Klaidos standartinis nuokrypis	0.010018			



kNN klasifikavimo modelio vertinimas


	Accuracy	Precision	Recall	F1	AUC	Sumaišymo matrica
3 požymiai	0.98	0.980048	0.98	0.9799995	0.9966	02 01955 23197
UMAP 2D	0.9675	0.9675117	0.9675	0.9674998	0.9813	02 01946 27193

Naudoti kNN parametrai: k=5. Požymių tvarka: RR_r_0/RR_r_1, wl_side, P_val

Naudoti UMAP parametrai: n_neighbors = 200, min_dist = 0.5, n_components = 2, metric = "euclidean"

Iš viso	Normalių reikšmių	Mild išskirčių	Extreme išskirčių	Matrica (mild)
400	384	16	0	02 061 209

KNN klasifikavimas (UMAP)
Testavimo aibė.



Random Forest klasifikavimo algoritmas

- Sudėtinis mašininio mokymosi metodas, naudojantis daugelio sprendimų medžių rinkinį.
- Priklauso godžiųjų (angl. *eager*) algoritmų grupei: modelis išmokomas iš anksto, prieš klasifikavimą.
- Galutinis sprendimas gaunamas pagal visų medžių balsų daugumą.

Veikimo principas:

1. Bootstrap imtys – kiekvienas medis treniruojamas iš atsitiktinai atrinkto duomenų poaibio.
2. Atsitiktinis požymių parinkimas – kiekvieno skaidymo metu naudojamas tik atsitiktinis požymių pogrupis.
3. Nepriklausomų medžių augimas – kiekvienas medis mokosi atskirai ir formuoja savo sprendimų struktūrą.
4. Balsų dauguma – klasifikavimo atveju visi medžiai balsuoja, o dominuojanti klasė tampa prognoze.

Random Forest optimalių parametru nustatymas

Vilniaus
universitetas

Numatytieji parametrai

Parametrai	Accuracy	Precision	Recall	F1	Sumaišymo matrica
ntree=500	0.990625	0.9906442	0.990625	0.9906249	0 2
					0 159 1
					2 2 158

Geriausi parametrai nustatyti eksperimentuojant su ntree reikšmėmis nuo 5 iki 1000

Parametrai	Accuracy	Precision	Recall	F1	Sumaišymo matrica									
ntree=100-1000	0.990625	0.9906442	0.990625	0.9906249	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>159</td><td>1</td></tr><tr><td>2</td><td>2</td><td>158</td></tr></table>		0	2	0	159	1	2	2	158
	0	2												
0	159	1												
2	2	158												

Požymių eiliškumo tyrimas (Random Forest)


Požymių eilės tvarka turi įtakos Random Forest klasifikatoriaus veikimui.

Požymių eilės tvarka	Accuracy	Precision	Recall	F1	Sumaišymo matrica
RR_r_0/RR_r_1, wl_side, P_val	0.990625	0.9906442	0.990625	0.9906249	02 01591 22158
wl_side, P_val, RR_r_0/RR_r_1	0.987500	0.9875762	0.987500	0.9874995	02 01591 23157
wl_side, RR_r_0/RR_r_1, P_val	0.987500	0.9875762	0.987500	0.9874995	02 01591 23157
P_val, RR_r_0/RR_r_1, wl_side	0.984375	0.9843939	0.984375	0.9843748	02 01582 23157
P_val, wl_side, RR_r_0/RR_r_1	0.984375	0.9843939	0.984375	0.9843748	02 01582 23157
RR_r_0/RR_r_1, P_val, wl_side	0.984375	0.9843939	0.984375	0.9843748	02 01582 23157

Geriausi rezultatai pasiekti su pradine požymių eilės tvarka: RR_r_0/RR_r_1, wl_side, P_val bei ntree=500.

Rinkinio sumažinimas iki dvimatės dimensijos (Random Forest)

Random Forest klasifikatoriaus veikimas UMAP dvimatėje erdvėje, naudojant validavimo duomenų aibę.



UMAP parametrai	Random Forest parametrai	Accuracy	Precision	Recall	F1	Sumaišymo matrica									
n_neighbors = 200, min_dist = 0.5	ntree = 500, RR_r_0/RR_r_1, wl_side, P_val	0.965625	0.9656432	0.965625	0.9656247	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>155</td><td>5</td></tr><tr><td>2</td><td>6</td><td>154</td></tr></table>		0	2	0	155	5	2	6	154
	0	2													
0	155	5													
2	6	154													


10 Hold-out eksperimentų (Random Forest)

Hold-out 10 iteracijų
rezultatai su 3 požymių
rinkiniu

	Accuracy	Precision	Recall	F1
Vidurkis	0.9831250	0.9831814	0.9831250	0.9831244
Dispersija	0.0000286	0.0000284	0.0000286	0.0000286
Vidutinė klasifikavimo klaida	0.016875			
Klaidos standartinis nuokrypis	0.005325			

Hold-out iteracijų
rezultatai su sumažintu
iki UMAP 2D rinkiniu

	Accuracy	Precision	Recall	F1
Vidurkis	0.9603125	0.9605551	0.9603125	0.9603071
Dispersija	0.0000717	0.0000714	0.0000717	0.0000717
Vidutinė klasifikavimo klaida	0.039688			
Klaidos standartinis nuokrypis	0.008469			



Random Forest klasifikavimo modelio vertinimas


	Accuracy	Precision	Recall	F1	AUC	Sumaišymo matrica									
3 požymiai	0.9875	0.9876097	0.9875	0.9874993	0.9985	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>199</td><td>1</td></tr><tr><td>2</td><td>4</td><td>196</td></tr></table>		0	2	0	199	1	2	4	196
	0	2													
0	199	1													
2	4	196													
UMAP 2D	0.9675	0.9677924	0.9675	0.9674949	0.9858	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>196</td><td>4</td></tr><tr><td>2</td><td>9</td><td>191</td></tr></table>		0	2	0	196	4	2	9	191
	0	2													
0	196	4													
2	9	191													

Naudoti Random Forest parametrai: ntree=500.
Požymių tvarka: RR_r_0/RR_r_1, wl_side, P_val

Naudoti UMAP parametrai: n_neighbors = 200, min_dist = 0.5, n_components = 2, metric = "euclidean"

Iš viso	Normalių reikšmių	Mild išskirčių	Extreme išskirčių	Matrica (mild)									
400	384	16	0	<table><tr><td></td><td>0</td><td>2</td></tr><tr><td>0</td><td>6</td><td>1</td></tr><tr><td>2</td><td>0</td><td>9</td></tr></table>		0	2	0	6	1	2	0	9
	0	2											
0	6	1											
2	0	9											

Random Forest klasifikavimas (UMAP)
Testavimo aibė





Hold-out eksperimentų rezultatų palyginimas

Vilniaus
universitetas

	Rinkinys	Accuracy		Precision		Recall		F1		Vidutinė klasifikavimo klaida	Klaidos standartinis nuokrypis
		Vidurkis	Dispersija	Vidurkis	Dispersija	Vidurkis	Dispersija	Vidurkis	Dispersija		
kNN	3 požymiai	0.9834375	0.0000696	0.9834922	0.0000694	0.9834375	0.0000696	0.9834370	0.0000696	0.016562	0.00834
Random Forest	3 požymiai	0.9831250	0.0000286	0.9831814	0.0000284	0.9831250	0.0000286	0.9831244	0.0000286	0.016875	0.005325
kNN	UMAP 2D	0.9703125	0.0001004	0.9704863	0.0000996	0.9703125	0.0001004	0.9703095	0.0001004	0.02968	0.010018
Random Forest	UMAP 2D	0.9603125	0.0000717	0.9605551	0.0000714	0.9603125	0.0000717	0.9603071	0.0000717	0.039688	0.008469

Geriausio klasifikatoriaus pasirinkimas

	Rinkinys	Accuracy	Precision	Recall	F1	AUC	Sumaišymo matrica						
kNN	3 požymiai	0.98	0.980048	0.98	0.9799995	0.9966	<table><tr><td>0</td><td>2</td></tr><tr><td>0 195</td><td>5</td></tr><tr><td>2</td><td>3 197</td></tr></table>	0	2	0 195	5	2	3 197
0	2												
0 195	5												
2	3 197												
Random Forest	3 požymiai	0.9875	0.9876097	0.9875	0.9874993	0.9985	<table><tr><td>0</td><td>2</td></tr><tr><td>0 199</td><td>1</td></tr><tr><td>2</td><td>4 196</td></tr></table>	0	2	0 199	1	2	4 196
0	2												
0 199	1												
2	4 196												
kNN	UMAP 2D	0.9675	0.9675117	0.9675	0.9674998	0.9813	<table><tr><td>0</td><td>2</td></tr><tr><td>0 194</td><td>6</td></tr><tr><td>2</td><td>7 193</td></tr></table>	0	2	0 194	6	2	7 193
0	2												
0 194	6												
2	7 193												
Random Forest	UMAP 2D	0.9675	0.9677924	0.9675	0.9674949	0.9858	<table><tr><td>0</td><td>2</td></tr><tr><td>0 196</td><td>4</td></tr><tr><td>2</td><td>9 191</td></tr></table>	0	2	0 196	4	2	9 191
0	2												
0 196	4												
2	9 191												



Geriausias klasifikatorius – Random Forest, nes jis pasiekė aukščiausius klasifikavimo rodiklius (Accuracy ≈ 0.9875 , AUC ≈ 0.9985), minimalų klaidų skaičių (0.016875) ir didžiausią stabilumą (vid. klaidos SD ~ 0.005325), o kitų metodų veikimas buvo žemesnis: kNN (Accuracy ≈ 0.98 , AUC ≈ 0.9966).

UMAP projekcija nepagerino rezultatų, todėl klasifikavimui tinkamesnis atrinktų požymių rinkinys.